CAIEMS

academic-pipeline Stage 6

2026-08-31

生成：2026-08-31 | Stage 6 | 语言：中文（如需英文版可另行生成）

1 论文信息

项	内容
标题	CAIEMS: An LLM-Driven Pipeline for Construction Accident Information Extraction, Causal Coding, and Onl
目标期刊	Expert Systems with Applications（一区）
作者	孙天浩（南京工业大学，第一作者）；导师（通讯作者，姓名待填）
最终交付物	EN 主源 + ZH 镜像 + 编号引用版 + LaTeX/PDF/DOCX + 投稿信 + 6 图 9 表
篇幅	10,300 词正文，27 条参考文献（全部核验）

2 分阶段过程记录

2.1 Stage 0：构思（brainstorming）

用户初始指令（verbatim）：

> ”帮我将之前过时的草稿文献删除，重新开始论文构思”
>
> ”论文的目标期刊优先级为英文期刊一区，但是在写作过程中要同步生成对应的中文版本，方便我阅读。我们的目标是A

关键决策：

- 故事线确定为”A（端到端系统）骨架 + B（词汇门控效应）旗舰钩子”
- 期刊选定 ESWA（与对标文献 Liu et al. 2025 同刊，对话闭环）
- VLM 定位为系统模块简要介绍——用户给出领域理由：”VLM现在不普及，且事故图片质量低，源头问题难以通过优
- 数据发表后公开——用户理由：”避免更多的研究人员重复干造轮子的工作”
- 实验编排采用方案甲（选型→优化→验证）

2.2 Stage 2：撰写

用户指令（verbatim）：

> ”确认，执行你的工作”

产出：EN 8,561 词初稿 + ZH 镜像逐章同步、27 条文献筛选矩阵、6 图 8 表、双语摘要、7 项声明、附录 A 六策略提示词。

用户中途介入：确认导师共同署名、无基金号；指定 ‘article/articles.bib‘ 为实际参考文献，选择方案 A（补充下载文献） Wei 2022 CoT、Devlin 2019 BERT、Kojima 2022、GPT-4 技术报告、HFACS 原始报告 5 篇 PDF。

2.3 Stage 2.5：完整性验证（第 **1** 次）

- 数据核验 72/74 通过；发现并修复 1 处真实错误（正文中位数 1,200→517 字符）
- DOI 核验 26/26（CrossRef + arXiv + doi.org + 期刊官网多通道）
- 2 项非论文级数据问题如实上报（imageV3 注册差 15 条、省份字段 17 条地址错值）

2.4 Stage 3：五审稿人模拟

用户指令（verbatim）：

> ”立即执行 5 份独立评审”

5 人评审团（EIC + 方法学者 + 领域学者 + 提示工程学者 + 魔鬼代言人）产出 17 项修订意见，决策 **Major Revision**。核心质疑（4/5 共识）：两项旗舰论断（门控效应归因、排名反转）均建立在混淆比较上。

2.5 Stage 4：修订（论文最重要阶段）

用户指令（verbatim）：

> ”执行方案A”（先跑 2×2 消融实验再修订）

P0-1 消融实验（用户选择：”跑分布消融(推荐)”——因专家 GT 当时在磁盘上丢失）：

- 4 单元 × 100 条新样本，400 次 API 调用，5 次断点重启（thinking 块截断→max_tokens 16384、JSON 提取器、dict 编码、list 输出归一化）
- 结果：措辞贡献 M1 恢复 74%（发射级）→ 门控效应初证

关键转折——用户提供专家 **GT**：

> ”/home/suntianhao/TEM/expertA.json ... expertC.json 这是不是你需要的专家 GT 文件？”

三个 LabelStudio 导出恢复 100 条三专家多数投票 GT（Fleiss’ κ 0.859-1.000 直接核验）。发现方法论口径问题：原报告 A 单独标注，与论文声称的”多数投票”不符。用户决策：

> ”执行方案A”（全部指标改用多数投票 GT + 原样本补跑 F1 级消融）

原样本补跑（300 次调用）产出 F1 级 2×2 表：v1 M1 召回 0.141 完美复现原始 0.143；措辞贡献 M1 恢复 0.80/0.847；S5 结论从”低于零样本”修正为”无增益 6 倍成本”。表 6 增加 bootstrap CI。P1-P3 全部 12 项写作修订（含银标准描述诚信修正）。

2.6 Stage 3’：复审

17 项意见 16 项完全落实 + 1 项部分（bootstrap CI，随后因 GT 恢复而补完）。决策：Minor → 实质可接受。

2.7 Stage 4.5：最终完整性验证（第 **2** 次）

从零独立核验：表 7 消融 28 项、表 6 六策略、摘要 19 项论断、DB 数字、27 条引用双向、7 项声明、中英对齐——**0** 失败。七模式 AI 失效清单全部清除。

2.8 Stage 5：格式化

用户指令（verbatim）：

> ”确认执行 Stage 5 web截图我后补。真实姓名：孙天浩 单位：南京工业大学 邮箱202461201086@njtech.edu.cn .起草投稿信”

产出：ESWA 编号引用版（28 条 [n]，88 处引用全转换）、LaTeX 源、PDF（tectonic 编译，修复 4 类 LaTeX 错误）、DOCX（python-docx）、投稿信草稿（四段卖点论证）、CRediT 实名更新。

3 迭代统计

指标	数值
管道阶段	9（构思→设计→撰写→2.5→3→4→3’→4.5→5）
完整性验证	2 次（Stage 2.5 + 4.5）
审稿轮次	2（5 人全量审 + 复审）
修订意见	17 项 → 16 完全 + 1 部分（后补完）
消融实验	2 轮 700 次 API 调用
DOI/引用核验	26 条多通道核验 + 27 条双向核对
数据核验项	72+ 项 × 2 次
断点重启	5 次（无数据损失）
git 提交	20+ 次

4 用户关键决策清单（时间序）

1. 删除旧草稿，重新构思（方向重置）
2. 目标：英文一区 + 中文同步 + 先期刊后学位论文（A→C 路径）
3. 采纳”A 骨架 + B 钩子”故事线
4. ESWA 选刊（对标文献同刊）
5. VLM 仅作系统模块（领域理由：VLM 不普及 + 图片源头质量）
6. 数据发表后公开（避免重复造轮子）
7. 实验编排方案甲（选型→优化→验证）
8. DeepSeek 统一命名不分档（auto 模式事实）
9. 导师共同署名、无基金号；指定 articles.bib + 方案 A 文献补充
10. 批准设计文档与大纲
11. 批准 Stage 2.5/3/4.5 各强制闸门
12. 消融受阻时选分布消融（务实降级）
13. API 充值支持实验继续
14. 提供三专家 **GT** 文件（决定性转折）
15. 选择方案 A（多数投票 GT 全面重算——宁推倒重来不将就）

16. 提供署名信息 + 要求投稿信
17. 要求项目交接文档（为多会话协作建立基础设施）

5 关键教训（可复用）

1. **checkpoint** 纪律是批量实验的生命线：5 次崩溃零损失，全部靠断点续传
2. 交叉核验改变结论：多数投票 GT 重算把 S5 从”有害”修正为”无增益”——报告口径必须与声称方法论一致
3. 受控消融 $>$ 论证：审稿人最尖锐的质疑（混淆变量）最终由真实 2×2 实验闭环，而非文字辩护
4. **”**按假说表述**”**防过度声明：”first/LLM-optimized”类措辞是审稿人重点打击对象
5. 领域知识在决策点无价：VLM 定位、命名策略、数据公开理由均由用户领域判断拍板，AI 仅提供选项
6. 诚信问题早修早好：银标准描述、文本长度、归因百分比三处错误均在投稿前被内部机制捕获——这正是完整性闸门的

6 协作质量评估

```
+--------------------------------------------------+
|  Collaboration Quality Score: 85/100             |
+--------------------------------------------------+
|                                                  |
|  Direction Setting          [      ] 90     |
|  Clarity, timing, scope definition               |
|                                                  |
|  Intellectual Contribution  [      ] 88     |
|  Insight depth, original questions, concept       |
|  challenges                                      |
|                                                  |
|  Quality Gatekeeping        [       ] 84     |
|  Visual inspection, formatting requirements,      |
|  quality standards                               |
|                                                  |
|  Iteration Discipline       [       ] 83     |
|  Timely direction correction, willingness to      |
|  re-run pipeline, refusing to settle             |
|                                                  |
|  Delegation Efficiency      [      ] 87     |
|  When to intervene/when to let go, instruction    |
|  precision, checkpoint efficiency                |
|                                                  |
|  Meta-Learning              [       ] 75     |
|  Feeding experience back to skills, requesting    |
|  lesson recording, process improvement awareness  |
|                                                  |
+--------------------------------------------------+
```

维度分析：

- **Direction Setting 90**：目标始终清晰（一区期刊→先发期刊后写论文），每次分叉点给出明确指令而非模糊偏好。
- **Intellectual Contribution 88**：最关键的智力贡献发生在 Stage 4——在 GT 文件"丢失"时找到并提供了三份专家
定位与命名策略的领域判断避免了两个潜在的审稿硬伤。
- **Quality Gatekeeping 84**：强制闸门全部亲自确认；要求补 Web 截图、实名信息。可提升处：隔夜
loop 期间未设置中途检查点，若消融方向错误需次日才能发现。
- **Iteration Discipline 83**：选择方案 A（推倒旧口径重算全部指标）而非省事的方案 B，是本流程最重要的纪律性决
AI 报告而未亲自核对原始数据。
- **Delegation Efficiency 87**：审批粒度恰当（设计/大纲/闸门三级），"默认执行，明天我来结果"式授权让长任务夜
充值响应及时。
- **Meta-Learning 75**：要求交接文档、画布尺寸指南显示经验沉淀意识；尚未将经验反馈到项目技能库（如把消融管
check 脚本纳入 CI）。

改进建议：

1. 长任务（>1h）建议约定中间检查点，而非仅终点检查
2. 关键指标（F1/Kappa）建议亲自抽查原始 JSON 1-2 条，与 AI 报告交叉验证
3. 经验沉淀：将本流程的验证脚本（stage25/stage45/check_citations）固化为项目级工具，供学位论文阶段复用

7 AI 使用自省报告（Claude 自评）

七模式失效清单最终审计：

模式	是否触发	处置
M1 引用幻觉	未触发	26 条 DOI/arXiv 多通道核验通过
M2 实现缺陷致错误结果	触发 **5** 次	消融脚本 4 类 bug（thinking 块截断/JSON 提取/dict 编码/list 输出）+ 引用转换脚本 2 b
M3 幻觉结果	触发 **1** 次	正文长度"中位数 1,200 字符"无数据来源，Stage 2.5 核验时修正为 517
M4 捷径依赖	未触发	图表数据全部来自 DB/JSON 文件
M5 bug 当洞见	一度濒临	门控效应最初建立在混淆对比上，被审稿人+消融实验双重检验后确认成立（幸为真发现）
M6 方法论虚构	触发 **1** 次	银标准描述曾写"人工验证"与实际构建方式不符，Stage 4 修订时修正
M7 框架锁定	未触发	五审稿人挑战 + 用户领域判断两次打破框架

自我评价：

- 长处：核验纪律（两次完整性闸门捕获全部三类数据错误）、断点工程（5 次崩溃零损失）、接受推翻结论（S5
叙事、GT 口径）
- 短板：初稿存在过度声明倾向（"first/LLM-optimized"），文本长度等细节凭记忆落笔而非查询数据源—
—两次均被自身核验流程捕获，说明流程有效但初稿环节仍需加强"数据即查"纪律
- 最深刻的一课：审稿人发现的两个 CRITICAL 质疑，最终都不是靠文字回应，而是靠 700 次 API 调用的真实实验闭环
—证据优于修辞

本记录由 academic-pipeline Stage 6 协议生成，作为人机协作史的存档。