CAIEMS LLM

Tianhao Sun[1], [Supervisor name][1,*]

2026-09-14

1 摘要

建筑施工事故报告是安全知识中规模大而利用不足的资源，将其转化为可分析记录至今仍依赖大量人工。本文提出CAIEMS——一条探索性 LLM 数据工程管道，将公开可获取的中文施工事故叙述加工为可查询的数据库原型：2,623 条记录、33 个字段、17,364 条致因标注。标注采用三层证据分级方案：逐字证据编码、语义归纳编码与领域先验推断编码，文本分类、结构化字段抽取、基于 CAICS 操作性编码方案（5 层 19 类）的致因编码、MECE 字段标准化与交互式 Web/REST 界面。三项支撑实验均以明确限定的口径报告。其一，4 个 LLM 在 200 条记录上的约束性比较：所选模型基础91.2%，且为候选模型中成本最低者；需说明的是各模型运行条件并不对等（温度约束与输出预算不同），因此这是面向选型条记录、三专家多数投票真值上的六策略提示对比（少样本最优，F1=0.669），期间观察到一种提示措辞敏感性——我们称之为词汇门控效应：疑问式条件检查措辞抑制了隐性类别的同义证据（M1 召回 0.141），同一设置下两步判断改写M1 召回提升至 0.941。我们将其报告为带实用补救的观察性现象，而非已分离的因果机制。其三，协议研究（n=289）：L与一名受训标注者在六项基础字段上达到高一致性（分类字段 Cohen's kappa 0.91–0.97；计数字段 ICC 0.985；日期年-月匹配率 99.7%）。全文对结果的边界作显式声明：银标准部分由模型输出构建，提示开发与最终测试共用同一样本，数据

关键词：大语言模型；建筑施工安全；信息抽取；提示工程；事故数据库；致因标注；标注者一致性

2 1. 引言

建筑业仍是全球最危险的行业之一。每起施工亡人事故都会产生调查报告与新闻报道，记录发生了什么、如何发生、为何发and Ahn, 2024）。

针对这一转化问题的既有计算路径可分为三类。BERT 及其蒸馏变体等监督分类器依赖标注语料，而该领域的标注语料et al., 2025）。基于 LLM 的研究已演示了从 OSHA 叙述中提取事故属性（Ahmadi et al., 2024）、对韩国坠落事故做 HFACS 分类（Kim and Han, 2024）、从施工报告构建知识图谱（Liu and Luo, 2025）的可行性。但这些成果大多止步于

本文报告的是 CAIEMS——一项探索性数据工程工作，而非理论证实性研究。唯一的组织性问题是实践性的：一个小团LLM API 与有限算力，将公开可获取的中文事故叙述转化为可查询的数据库，并使标签在明确界定的置信层级上可追溯到原

这一框架对应三项贡献。(C1) 数据工程管道与数据库原型：2,623 条记录、33 字段、17,364 条三层分级致因标注，配 Web 界面与 REST API；数据与代码于论文发表后开放检查。(C2) CAICS 操作性编码方案——面向施工事故致因的 5 层 19 类操作定义，明确将其定位为本数据库的操作性方案，而非新的致因理论。(C3) 一个经验记录的提示措辞敏感性——词汇门控效应——在提示开发过程中观察到，并配有带边界声明的两步判断补救。

三项支撑实验锚定可靠性讨论。实验一在 200 条记录上比较 4 个 LLM 以支持骨干选型，并显式声明运行条件不对等的保100 条记录、三专家多数投票真值上比较六种提示策略；该实验发现了上述措辞敏感性。实验三在 289 条记录上测量 LLM 与一名受训标注者在六项基础字段上的一致性。各实验所用样本的已知局限——银标准部分由模型产出、策略样本同时——均在每次使用处声明，而非集中于一段笼统的保留说明。

论文其余部分组织如下：第 2 节综述相关工作；第 3 节描述证据分级方案、CAICS 操作定义、管道架构与数据库；第 4 节按声明口径报告三项实验；第 5 节讨论意义与局限；第 6 节总结。

3 2. 相关工作

3.1 2.1 施工事故文档的文本分析

施工安全文档的计算分析早于 LLM。对人工编码记录做关联规则挖掘识别了事故类型与致因因素间的可解释关联（Rafinda et al., 2023）；对 OSHA 屋面工人记录做决策树建模产出了伤害预测规则（Onuchukwu et al., 2024）。Ayhan and Tokdemir (2019) 在专家编码事件集上结合回归与模糊逻辑。这些研究的共同约束是循环性的：分析质量受制于结构 et al. (2025) 直面转化环节，在 5,224 条施工事故案例上对比 TF-IDF、BERT、RoBERTa、XLNet 与 DistilBERT 的安全属性提取，发现 DistilBERT 以约一半的计算成本取得相近性能。其结果是监督范式的典型写照：可用的 F1=0.72）以大规模标注语料为代价。

3.2 2.2 LLM 事故信息抽取

LLM 通过无需任务特定训练、直接从文本推断结构改变了瓶颈位置（Brown et al., 2020; OpenAI, 2023）。Ahmadi et al. (2024) 评测 GPT-3.5、GPT-4.0、Gemini Pro 与 LLaMA 3.1 对 OSHA 施工报告的分类。Zhang, Hou, et al. (2025a) 构建了基于 GPT 的地铁施工报告分析对话系统 AIR Agent。Liu, Ding, et al. (2025b) 将零样本 GPT-4o 抽取应用于 1,097 条高处坠落报告，实体识别 F1=0.94。相邻领域中，Huang et al. (2026) 为海事事故构建了带质量评估框架的 LLM 知识图谱管道，Jiang et al. (2026) 构建了带本体建模与交互可视化 抽取与图谱存储；差异在于数据质量报告的深度、是否存在人工验证的参考标准、以及产物是否作为可更新服务维护。

3.3 2.3 基于 HFACS 的 LLM 致因分类

人因分析与分类系统（Shappell and Wiegmann, 2000）主导高风险行业的致因分类。思维链提示（Wei et al., 2022）及其变体——零样本推理（Kojima et al., 2022）、自洽解码（Wang et al., 2023）与从易到难分解（Zhou et al., 2023）——构成基于提示的分类方法的方法论基座。Liu et al. (2025a) 提出 HFACS-CoT，在 113 条通用航空叙述上以 GPT-4o 比较六种提示策略，发现领域 CoT 更优（召回 74.9%、精确 46.2%）。Kim and Han (2024) 将 HFACS 与 Claude 3.5 Sonnet 结合分析 1,816 条韩国施工坠落案例。Yan et al. (2025) 跨七个 LLM 应用 HFACS 引导提示。Ahmadi et al. (2025) 探索了 Llama-3.1 8B 的 GRPO 微调路线。纵观该文献，策略排名均在单一模型-任务组合内建立，提示设计被报告为"可用配置"，鲜有系统考察嵌入知识的

3.4 2.4 知识图谱与事故数据库

Kong and Ahn (2024) 系统综述了施工安全管理知识图谱，并指出研究原型与运营平台之间的差距。Liu and Luo (2025) 以迭代 CoT 提示生成施工事故知识图谱。Yang and Park (2025) 构建了道路事故新闻知识图谱。Zhang, Wei, et al. (2025b) 开发了面向流程工业事故知识的图检索增强问答系统 GRAG-ProSafe。Shi et al. (2025) 将故障树、贝叶斯网络与本体推理结合用于基坑坍塌分析。Xiao et al. (2026) 将知识图谱作为 LLM 人因可靠性分析的检索 —优先可追溯的分级证据标注与可更新的查询接口，并以测量的边界报告标注的可靠性。

4 3. 系统

4.1 3.1 问题形式化与证据分级标注方案

令 $T = \{t_1, t_2, \ldots, t_N\}$ 表示非结构化事故叙述语料（本语料中位数 517 字符）。管道将每条 t_i 转化为结构化记录 $r_i = (b_i, c_i)$：基础信息向量 b_i 覆盖 33 个预定义字段；致因标注集 $c_i = \{(x_ij, e_ij, \iota_ij, q_$ x_ij 为 CAICS 方案中的致因编码，e_ij 为支撑文本，ι_ij 为推理链，$q_ij \in \{\text{explicit}, \text{inferred}, \text{prior}\}$ 为证据层级。

三个层级承担不同的认识论承诺，数据库分开存储、分开报告：

- **explicit**（逐字证据）：原文含直接支撑该编码的表述，e_ij 为逐字引文。Web 界面中仅此类编码呈现为"有证据支

- **inferred**（语义归纳）：编码由叙述经同义改写归纳得出（如"安全管理不到位"在未引用任何固定关键词的情况下支
  M1）。推理链已记录。

- **prior**（领域先验）：编码来自提示中授权的领域假设（如亡人事故视为隐含监管缺失，即使文本未提）。此类编码带

该方案取代了早期草稿中"每个编码均带可引用证据、无证据即幻觉"的更强声明。分层方案才是对生产提示实际行为的准确
17,364 条标注中，explicit 15,809 条（91.0%）、inferred 1,131 条（6.5%）、prior 424 条（2.4%）；本文报告总量，并在

4.2 3.2 CAICS：操作性编码方案

建筑施工事故综合致因系统（CAICS）是面向施工事故叙述的 5 层 19 类编码方案。其层级遵循因果泄漏模型：管理层（M)
1 列出十九类及其操作定义与典型证据关键词。

表 **1. CAICS** 编码方案：操作定义

[表1占位：待手绘 — 5 层 19 类操作定义表]

CAICS 与源自航空领域的 HFACS 改编（Shappell and Wiegmann, 2000; Liu et al., 2025a）有两个设计差异：F
层刻画施工领域普遍的物理防护失效，C 层记录迟报瞒报等后果放大因素。方案经泄漏模型指导下的语料驱动归纳得出：从
24Model（Xuecai et al., 2024）、Accimap 或 HFACS 做对比验证。因此本文将 CAICS 定位为本数据库的操作性方案——
——面向 LLM 的有限编码框架，配显式定义——而非已经确立的致因理论。其可用性证据包括 100 条策略样本上的专家标注
kappa 各层 0.859–1.000，见 4.1 节）。

4.3 3.3 管道架构

图 1 展示总体架构。管道由六个处理阶段与随后的存储、访问层构成。

图 **1. CAIEMS** 系统架构

[图1占位：待手绘 — 系统架构图]

阶段 **1**：多源采集。 爬虫从公共安全信息门户（safehoo.com、esafety.cn）与地方应急管理局网站采集事故报告，原始
HTML 解析为候选记录。语料由两个时间块构成：历史块（1978–1990，698 条，占 26.6%），数字化自公开事故汇编；当
2026，1,925 条，占 73.4%），采集自新闻门户；1991–2004 年无记录。中国承包商海外工地事故（22 条境外记录）保留于

阶段 **2**：**LLM** 文本分类。 候选页面异质性显著。轻量 LLM 分类器以五个标注示例的少样本提示为每条记录分配
single / multi / other 三种类型。该阶段移除了 895 条教材记录及全部广告、导航页面。需说明的是分类器并不完美：一致
300 条抽样中仍有 11 条在标注时因含多起事故被排除，说明文本分类存在残留错误，当前管道尚未对其完全审计；多事故拆

阶段 **3**：基础字段抽取（**Step 1**）。 对每条通过分类的记录，LLM 在严格 JSON 工具模式下抽取 33
字段基础信息向量。评测运行中 100% 记录获得符合 schema 的输出。抽取器同时产出规范化标题摘要用于搜索增强。

阶段 **4**：**CAICS** 致因编码（**Step 2**）。 编码器应用两步判断流程——显性匹配后授权推断——并为每个编码记录证据
节）。图 2 以一条真实记录的示例展示五层结构。

图 **2. CAICS** 五层结构与示例证据链

[图2占位：待手绘 — CAICS 五层结构与示例证据链]

阶段 **5**：**LLM** 优先的 **MECE** 枚举标准化。 五个自由文本字段（工序、设备、材料、工种、建筑结构）经
LLM 优先流程规范化：LLM 审视字段取值分布、设计 MECE 框架、映射全部观察值。表 2 报告所得枚举，并显式给出非空

表 **2. LLM** 优先流程产出的 **MECE** 枚举

字段	类别数	非空记录（占 2,623）	最大类别（占非空）	残余"其他"（占非空）
工序（WT）	11	2,202（83.9%）	WT02 主体结构工程（397，18.0%）	2.9%
涉事设备（EQP）	13	1,373（52.3%）	EQP01 起重机械（335，24.4%）	1.9%
涉事材料（MAT）	7	1,465（55.9%）	MAT01 混凝土及水泥制品（423，28.9%）	11.1%
工种（WKR）	13	1,905（72.6%）	WKR01 通用劳务工（928，48.7%）	6.3%
建筑结构（BLD）	12	359（13.7%）	BLD01 钢结构（127，35.4%）	3.6%

阶段 **6**：存储与访问。 全部产物存储于含九张表的 SQLite 数据库。交互式 Web 平台与 REST API
开放访问：用户可按事故类型、等级、地区、工序与致因编码筛选，并查看每条标注背后的证据（证据层级分开展示）。数

4.4 3.4 多模态扩展

文本之外，管道通过三个展示型模块增强记录：聚合搜索 API 的搜索增强（1,636 条，62.4%）、零样本 CLIP 分类器过滤的图片采集（226 张高于 0.5 相似度阈值）、以及 GLM-5V-Turbo 的两阶段 VLM 描述（282 条分析覆盖 176 起事故）。这些模块是扩展而非经评估的贡献：图片源头质量约束 VLM 分析的贡献，描述作为补充材料呈

4.5 3.5 数据库统计

表 3 汇总数据库，全部计数与总量闭合。

表 **3.** 数据库统计

维度	数值
事故记录	2,623
时间跨度	1978-08 至 2026-06（1991–2004 无记录）
事故类型	12 类，2,617 条有标注（坍塌 1,092；高处坠落 570；起重伤害 225；土方坍塌 222；触电 160；物体打击 119；其
事故等级	一般 1,889；较大 672；重大 53；特别重大 8；1 条未标注
伤亡	死亡 5,894；受伤 5,796
致因标注	17,364 条（explicit 15,809 / inferred 1,131 / prior 424）
搜索增强记录	1,636
CLIP 过滤图片	226
VLM 分析	282 条 / 176 起事故

图 3 展示十九个 CAICS 类别的标注分布；高频编码（M1 监管缺失、H1 违章操作、H3 风险辨识失败）部分反映生产损

图 **3.** 十九个 **CAICS** 类别的致因标注分布

[图3占位：待手绘 — CAICS 编码分布条形图]

5 4. 实验评估

评估以明确声明口径回答三个问题：管道在其实际成本约束下应采用哪个骨干模型（4.3 节）；致因编码提示应如何措辞（4 节）；LLM 的基础字段标注是否与受训人工标注者一致（4.5 节）。4.1 与 4.2 节定义数据集与指标。

5.1 4.1 数据集与抽样

全量语料。 管道产出 2,623 条单事故记录，跨 1978–2026 年，含 33 字段与 17,364 条分层致因标注。

银标准。 972 条银标准由管道版本一致构建，而非独立人工重标注：基础字段在两版本一致时直接采纳、不一致时规则裁 100 条子集获得了完全独立的人工验证：三位施工安全领域专家在 LabelStudio 平台上标注 CAICS 编码，Fleiss' kappa 在五层上介于 0.859 与 1.000；该子集真值为三专家多数投票，平均每条 5.1 个编码。

评测样本。

1. 模型比较样本（n=200）。按事故类型分层（11 类，每类至少 3 条）从银标准抽取。 2. 策略比较样本（n=100）。从 12 种事故类型与 19 个 CAICS 类别；致因真值为上述三专家多数投票。口径声明：该样本承担了提示开发—— ——发现 v1 召回问题、分析错误类别、设计 v2、运行消融、选定生产配置。开发与最终报告共用同一样本，因此策略结果带有 3. 一致性样本（n=289）。两阶段分层抽样（事故类型 × 等级，比例分配、每格保底 2 条）从 2,623 条全量语料抽取—— ——而非银标准。一名受训标注者（安全工程研究生）经 LabelStudio 标注六项基础特征（事故类型、等级、省份、死亡人数、 300 条中 11 条因多事故文本被排除。

图 4 汇总样本层级。

图 **4.** 数据集层级与三个评测样本

[图4占位：待手绘 — 样本关系流程图]

5.2 4.2 评测指标

基础字段抽取采用逐字段精确匹配准确率，地点字段做行政后缀归一化。致因编码按维度（管理、防线、触发、人的行为）F1，采用 Liu et al. (2025a) 的维度级匹配定义；六策略对比另报百分位 bootstrap 95% 置信区间（1,000 次重采样）。标注者一致性方面：分类字段用带 95% 置信区间的 Cohen's kappa，计数字段用 ICC(2,1)，日期用年-月匹配率——三种统计量按各自名称报告，不以单一标签统称。

5.3 4.3 实验一：显式约束下的骨干选型

四个候选模型在模型比较样本上评测：DeepSeek V4、Qwen 3.7、GLM 5.2、Kimi K2.6，使用相同系统提示与三个少样本 K2.6 按 API 规范强制 temperature 1.0；GLM 5.2 因推理痕迹需 16,384 token 输出预算；DeepSeek V4 经提供商自动档位路由访问，运行日志中的请求标识覆盖其档位家族。由于这些差异，且每种配置仅运行一次，本实验定位

表 4 报告逐字段准确率。三个最强模型总体达 91.2–91.5%，事故等级、死亡人数、省级地点普遍高准确。城市提取最难 88.0%）：中文报道常点名县级市而参考记录为上级地级市。Kimi K2.6 大幅落后（63.9%），与其强制温度带来的输出不

表 **4.** 基础字段提取准确率（%），实验一

字段	DeepSeek V4	Qwen 3.7	GLM 5.2	Kimi K2.6
事故类型	86.0	85.0	84.5	61.5
事故等级	98.0	90.5	97.5	69.5
死亡人数	96.0	96.0	97.0	68.5
受伤人数	90.0	91.0	91.0	58.5
省份	96.0	98.5	96.0	67.0
城市	81.5	88.0	83.0	58.5
总体	**91.2**	**91.5**	**91.5**	**63.9**

表 5 报告按维度的致因编码表现。DeepSeek V4 平均精确率最高（89.5%）、强模型间召回率最低（52.7%）；Qwen 3.7 呈镜像取舍（精确 78.0%、召回 80.5%）。成本与延迟补全选型图景：200 条记录成本 0.13 美元（DeepSeek V4）、0.43（Qwen 3.7）、2.91（GLM 5.2）、2.84（Kimi K2.6）；单条延迟 9.8 秒、8.6 秒、27.0 秒、74.9 秒。管道采用 DeepSeek V4。

表 **5.** 致因编码精确率 / 召回率 / **F1**（%），按维度，实验一

维度	DeepSeek V4	Qwen 3.7	GLM 5.2	Kimi K2.6
管理	89.9 / 54.9 / 68.1	67.5 / 95.6 / 79.1	92.3 / 63.7 / 75.4	97.6 / 36.3 / 52.9
防线	91.9 / 41.9 / 57.6	88.8 / 64.0 / 74.4	87.6 / 67.6 / 76.3	96.4 / 39.0 / 55.5
触发	81.0 / 69.4 / 74.7	72.4 / 85.7 / 78.5	73.9 / 69.4 / 71.6	81.5 / 44.9 / 57.9
人的行为	95.0 / 44.7 / 60.8	83.3 / 76.5 / 79.8	83.9 / 61.2 / 70.7	88.2 / 35.3 / 50.4
平均	**89.5 / 52.7 / 65.3**	**78.0 / 80.5 / 78.0**	**84.4 / 65.5 / 73.5**	**90.9 / 38.9 / 54.2**

5.4 4.4 实验二：提示策略对比与词汇门控观察

六种提示策略在策略样本（n=100，三专家多数投票真值）上以 DeepSeek V4（temperature 0.0）对比评测：S0 基础零样本、S1 基础少样本（三个专家标注示例）、S2 Auto-CoT、S3 计划与求解、S4 CAICS-CoT（两步判断领域知识 CoT）、S5 CAICS-CoT+（带层间摘要注入的串行逐层调用）。附录 A 以压缩形式收录各提示。

表 **6.** 六种提示策略性能（多数投票真值，**n=100**）

注。 真值为三位独立专家标注者的多数投票。置信区间为百分位 *bootstrap*（*1,000* 次重采样）。*S2* 的编码指标与类型/输出发生层级格式漂移）；其他策略未做后处理，因此 *S2* 的得分描述的是后处理管道而非原始输出。全部配置在 *temperature 0.0* 下各运行一次。*S1*、*S4*、*S5* 的 *F1* 差异处于重叠的置信区间内，故将 *S1* 描述为最高点估计，而非经统计确 S1 的示例实现格式-内容联合校准：示范输出 schema、期望编码密度、编码组合模式与推理深度。S1 的平均编码密度与真值对 5.1），S0 偏少（3.6）、S4 偏多（6.5）。与 Liu et al. (2025a) 的比较有信息量但存在混淆：两项研究在模型（GPT-4o 对 DeepSeek V4）、任务（航空 HFACS 对施工 CAICS）、语料与评测条件上同时不同。因此观测到的排名差异与模型任务组合的最优策略不能从单一已发表排名推定。

策略	平均 F1 [95% CI]	平均召回	平均精确	类型准确率	等级准确率	有效输出率	耗时(s)
S0 零样本	0.600 [0.520, 0.644]	0.515	0.808	0.630	0.960	96%	1,382
S1 少样本	**0.669 [0.615, 0.722]**	0.634	0.753	0.840	0.970	100%	1,302
S2 Auto-CoT	0.634 [0.564, 0.691]	0.564	0.772	0.860	0.980	85%	2,401
S3 计划与求解	0.598 [0.529, 0.652]	0.540	0.741	0.850	0.990	92%	1,735
S4 CAICS-CoT	0.656 [0.603, 0.695]	**0.872**	0.565	0.830	0.990	99%	1,843
S5 CAICS-CoT+	0.665 [0.606, 0.719]	0.750	0.618	0.830	0.980	100%	5,430

S4 初版提示（v1）将领域知识嵌入为条件检查：每个编码配一个疑问式门控（"文本提到'无人监管"监理失职'吗？"）加的 F1=0.503、召回=0.423、21% 空输出、M1 召回 0.141——而 M1 是真值中最高频编码（100 条中出现 85 次）。多数事故叙述从不使用这些精确措辞，而是写"安全管理不到位""未及时发现制止"。在条件检查措辞下，模型似乎

我们将这一观测模式命名为词汇门控效应：疑问式条件检查 CoT 措辞抑制隐性类别的同义证据，召回损失集中于最高频

补救以两步判断取代门控：(1) 显性匹配——文本是否以任何同义表述直接支持该编码？(2) 授权推断——根据事故性质与施工安全常识，该致因即使没有显式措辞是否必然存在？保守指令亦替换为全覆盖偏好。v1→v2 的组合变化将 F1 从 0.503 提至 0.656，召回从 0.423 提至 0.872，M1 召回从 0.141 提至 0.988，空输出从 21% 降至 0。图 5 可视化该变化。

图 **5.** 词汇门控观察及其补救

[图5占位：待手绘 — 门控效应观察与补救双面板图]

v1→v2 的转变同时改变了多个提示属性——疑问句式、两步判断的加入、推断的显式授权、输出政策指令。因此我们在 7 报告结果。保持保守指令不变，仅措辞改变（v1 → v2a）将 M1 召回从 0.141 提至 0.941——M1 总恢复量 0.847 中的 0.800——而保持措辞不变，仅政策改变（v1 → v2b）只提至 0.329。聚合层面两种操纵贡献相当（F1 +0.161 对 +0.150）。

两条范围边界随之而来。其一，这些是简单逐对差值，不是带交互项估计的正式因子分析，且四个格子在共享开发样本上 CAICS 任务上，提示措辞实质性地改变隐性类别的召回，两步判断是实用补救。我们不声称已分离因果机制。

表 **7.** 措辞与输出政策的四格比较（**n=100**，多数投票真值，**DeepSeek V4**，**temperature 0.0**）

单元	措辞	输出政策	F1	召回	精确	空输出	M1 召回	M3 召回	H3 召回
v1	条件检查	保守	0.503	0.423	0.856	21%	0.141	0.250	0.111
v2a	两步判断	保守	0.665	0.677	0.709	2%	0.941	0.667	0.511
v2b	条件检查	全覆盖偏好	0.653	0.641	0.724	5%	0.329	0.444	0.533
v2	两步判断	全覆盖偏好	**0.656**	**0.872**	0.565	0%	0.988	0.972	1.000
	Δ(措辞) = v2a − v1		+0.161	+0.254	−0.147	−19 pp	+0.800	+0.417	+0.400
	Δ(政策) = v2b − v1		+0.150	+0.218	−0.132	−16 pp	+0.188	+0.194	+0.422

生产编码器采用 S4 两步判断设计而非 S1。该选择偏向召回（0.872 对 0.634）与数据库所需的分层证据输出，代价是精 S1 的 F1 差距小且置信区间重叠。三层证据分级方案（3.1 节）即补偿设计：低精确编码按层级标注，下游用户得以区分逐字

5.5 4.5 实验三：LLM 与一名受训标注者的一致性

第三个实验测量 LLM 的基础字段标注是否与受训人工标注者一致。口径精确表述：这是一项单一 LLM 配置与一名标注者、项中）的一致性研究，不是专家级准确性的认证，也不涉及致因编码。

在一致性样本（n=289）上，LLM 与标注者独立标注六项字段。表 8 报告结果。三个分类字段的 Cohen's kappa 为 0.9136（事故类型）、0.9477（等级）、0.9746（省份）；两个计数字段的 ICC(2,1) 为 0.9849（死亡）与 0.9853（受伤），平均绝对误差每条 0.118 与 0.087；日期年-月匹配率 99.7%。三种统计量针对三种字段 kappa 标签统称。

表 **8. LLM** 与一名受训标注者在六项基础字段上的一致性（**n=289**）

另两条边界。其一，一致性不等于准确性：双方可能共同犯错，该样本无独立仲裁标签。其二，比较仅覆盖六项基础字段 100 条策略子集。早期草稿曾引用另一批 100 条三专家样本的专家间区间作为等效界限；因该样本与 289 条样本在构成与难 6 绘制各 kappa 值及其置信区间。

特征	指标	数值 [95% CI]	一致率
事故类型	Cohen's κ	0.9136 [0.8747, 0.9466]	93.4%
事故等级	Cohen's κ	0.9477 [0.9024, 0.9841]	97.6%
省份	Cohen's κ	0.9746 [0.9563, 0.9927]	97.6%
死亡人数	ICC(2,1)	0.9849 [0.9292, 0.9991]	MAE 0.118
受伤人数	ICC(2,1)	0.9853 [0.9426, 0.9995]	MAE 0.087
日期（年-月）	匹配率	0.9965	99.7%

图 **6. LLM** 与一名标注者在六项字段上的一致性

[图6占位：待手绘 — 一致性森林图]

6 5. 讨论

6.1 5.1 意义

对数据工程实践有三重推论，均在各自范围内陈述。其一，三层证据分级方案为"每个编码必须带逐字支撑"的全有或全无声明—管道正是如此。其二，措辞观察概括为一条设计告诫：在本模型与本任务上，疑问式条件检查措辞抑制了隐性类别的同义词恢复总量 0.847 中的 0.800）。设计召回关键抽取提示的实践者应测试措辞变体，而非假定所列关键词天然作为示例线索起作用。LLM 配置与一名受训标注者达到高协议一致性——这支持以 LLM 在人工监督下减轻（而非取代）这些字段的标注工作量。

6.2 5.2 与既有工作的对比

表 9 沿可据已发表报告比较的维度——数据来源、记录规模、人工验证、证据绑定、系统可访问性——将 CAIEMS 与代表性既有系统并置。我们将其呈现为描述性对比，而非排他性新颖性的证据；若干既有系统已组合了采集、LLM 抽取与图谱/数据库存储，本工作的侧重在分层证据标注与可更新查询接口。

表 **9.** 与代表性既有系统的描述性对比

系统	领域	LLM	编码方案	证据绑定	人工验证	交互访问
Liu et al. (2025a)	航空	GPT-4o	HFACS	无	专家标注数据集	无
Kim and Han (2024)	施工（韩）	Claude 3.5	HFACS	无	无	无
Ahmadi et al. (2024)	施工（美）	GPT-4.0	无	无	无	无
Liu and Luo (2025)	施工	GPT-4o	Accimap	无	无	无
Jiang et al. (2026)	煤矿	LLM	自定本体	无	无	仅可视化
CAIEMS（本文）	施工（中）	**DeepSeek V4**	**CAICS**（操作性）	分层	部分（**100** 条子集）	**Web + API**

6.3 5.3 局限性

以下按严重程度列出界定主要结论的局限性。

(1) 参考标准独立性。 972 条银标准部分由模型产出（管道版本一致加规则裁决）；仅 100 条致因子集承载独立三专家验—含公开标注指南、标注者背景、盲法、仲裁规则与逐类样本量——仍是未来工作。

(2) 开发-测试重叠。 100 条策略样本同时承担提示开发（v1 诊断、v2 设计、消融）与最终报告，三个少样本示例未按显

(3) 提示措辞推断。 四格比较在单一样本上报告简单逐对差值且各运行一次；未估计正式交互效应，也不支持模型内部机

(4) 模型比较条件。 四模型运行条件不对等（强制温度、输出预算、档位路由），各配置仅运行一次，模型标识记录在家

(5) 一致性范围。 一致性研究覆盖一名标注者、六项字段（33 项中）、无独立仲裁；致因编码缺大规模一致性研究。结果

(6) 数据库审计。 语料存在已知质量缺口：分类器的多事故残留错误未完全审计，跨源镜像报道未系统去重，字段缺失率 13.7%–83.9%），且因来源为公共新闻门户，语料过度代表严重事故。数据库覆盖公开可检索的事故报道；它不是全部施工

(7) 数据治理。 管道采集并计划再分发新闻门户与政府网站的文本与图片。公开可访问本身不足以解决再发布权利问题；7 节，须在公开前完成。

(8) 可复现性。 数据、代码与完整提示承诺发表后公开而非投稿时公开；单次运行配置与家族粒度模型标识限制精确复现

7 6. 结论

本文报告了 CAIEMS——一条探索性 LLM 管道，将公开可获取的中文施工事故叙述转化为可查询的数据库原型：2,623 条记录、33 字段、17,364 条三层分级致因标注，经 Web 界面与 REST API 服务。三项各带口径声明的支撑实验锚定可靠性：DeepSeek V4 的约束性四模型比较（91.2% 基础字段准确率、最低成本）；发现词汇门控观察及其两步判断补救的六策略提示 LLM 与一名受训标注者在六项基础字段上高一致性的协议研究。全文对结果边界作显式声明：银标准部分由模型产出、开发

8 7. 声明

数据可用性。 数据库的匿名只读快照、字段字典、来源清单与 CAICS 操作定义将在审稿期间应要求提供，并于论文发表后在 A；逐字提示包含于复现包。

代码可用性。 管道、评测脚本与实验运行器将于论文发表后以开源许可证随数据发布；审稿期间可向作者索取最小复现包

伦理与数据治理。 本研究分析公开新闻报道与政府发布的事故通报；结构化记录中不涉及人类受试者或可识别个人信息。URL 与抓取时间；对图片中的姓名与可识别面部做移除或遮蔽；应请求提供撤回删除机制；对创伤性影像设访问控制。无法

作者贡献（**CRediT**）。 孙天浩（南京工业大学）：概念化、方法、软件、数据整理、形式分析、调研、初稿撰写。[导

利益冲突声明。 作者声明无利益冲突。

基金资助。 本研究未获得公共、商业或非营利部门资助机构的专项资助。

AI 工具使用声明。 大语言模型既是本研究的对象，也是核心技术工具：第 3-4 节报告的全部抽取、分类与编码结果均由 LLM 写作辅助进行语言润色；全部科学内容、实验设计与数据出自作者工作并经作者核验。

参考文献

1. （与英文主源一致，列表见 eswa_paper_v2.md References 节）

Ahmadi, A., Sharif, S., Banad, Y. (2025). Improving Aviation Safety Analysis: Automated HFACS Classification Using Reinforcement Learning with Group Relative Policy Optimization. arXiv:2508.21201.

Ahmadi, E., Muley, S., Wang, C. (2024). Automatic Construction Accident Report Analysis Using Large Language Models (LLMs). Journal of Intelligent Construction, 3(1).

Ayhan, B.U., Tokdemir, O.B. (2019). Predicting the outcome of construction incidents. Safety Science, 113, 91–104.

Brown, T., Mann, B., Ryder, N., et al. (2020). Language Models are Few-Shot Learners. NeurIPS, 33, 1877–1901.

Devlin, J., Chang, M.-W., Lee, K., Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. NAACL-HLT 2019, 4171–4186.

Huang, Y., Yan, R., Zhang, Z. (2026). Automated knowledge extraction from marine accident reports using large language models. Ocean & Coastal Management, 272, 108015.

Jiang, Y., Nie, B., Wang, J., et al. (2026). Large language model-driven knowledge graph and intelligent analysis for coal mine accidents. Measurement, 277, 121558.

Kim, D., Han, S. (2024). Systemic Analysis of Fall Accidents Caused by Worker Inattention at Construction Sites. KIBIM Magazine, 14(4), 23–34.

Kojima, T., Gu, S.S., Reid, M., et al. (2022). Large Language Models are Zero-Shot Reasoners. NeurIPS, 35, 22199–22213.

Kong, F., Ahn, S. (2024). Use of Knowledge Graphs for Construction Safety Management: A Systematic Literature Review. Information, 15(7), 390.

Liu, Q., Ding, Y., Luo, X. (2025b). Automated knowledge graph-based risk assessment for fall-from-height accidents in construction. Automation in Construction, 179, 106482.

Liu, Q., Li, F., Ng, K.K.H., et al. (2025a). Accident investigation via LLMs reasoning: HFACS-guided Chain-of-Thoughts enhance general aviation safety. Expert Systems with Applications, 269, 126422.

Liu, Q., Luo, X. (2025). Large language model-based knowledge graph construction of unstructured accident reports. EG-ICE 2025.

Onuchukwu, I.S., Gholizadeh, P., et al. (2024). Nature of Occupational Incidents among Roofing Contractors. Buildings, 14(3), 595.

OpenAI (2023). GPT-4 Technical Report. arXiv:2303.08774.

Rafindadi, A.D., Shafiq, N., Othman, I., et al. (2023). Data mining of the essential causes of different types of fatal construction accidents. Heliyon, 9(2), e13389.

Shappell, S.A., Wiegmann, D.A. (2000). The Human Factors Analysis and Classification System–HFACS. Report DOT/FAA/AM-00/7.

Shi, D., Gan, S., Zurada, J., et al. (2025). A multi-model approach to construction site safety. Expert Systems with Applications, 288, 127817.

Togan, V., Mostofi, F., Tokdemir, O.B., et al. (2025). Efficient Management of Safety Documents Using Text-Based Analytics. IEEE Access, 13, 99758–99777.

Wang, X., Wei, J., Schuurmans, D., et al. (2023). Self-Consistency Improves Chain of Thought Reasoning in Language Models. ICLR 2023.

Wei, J., Wang, X., Schuurmans, D., et al. (2022). Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. NeurIPS, 35, 24824–24837.

Xiao, X., Chen, P., Qi, B., et al. (2026). KRAIL: A knowledge-driven framework for human reliability analysis. Reliability Engineering & System Safety, 265, 111585.

Xuecai, X., Gui, F., Shifei, S., et al. (2024). Accident case data-accident causation model driven safety training method. Process Safety and Environmental Protection, 182, 1208–1226.

Yan, Y., Li, B., Lodewijks, G. (2025). UAV Accident Forensics via HFACS-LLM Reasoning. Drones, 9(10), 704.

Yang, J., Park, S. (2025). LLM-Assisted Knowledge Graph Construction for Managing Road Accident Information. IEEE Access, 13, 217846–217865.

Zhang, L., Hou, Y., Ren, F. (2025a). AIR Agent—A GPT-Based Subway Construction Accident Investigation Report Analysis Chatbot. Buildings, 15(4), 527.

Zhang, J., Zhang, W., Wei, Q., et al. (2025b). GRAG-ProSafe QAS. Expert Systems with Applications.

Zhou, D., Schärli, N., Hou, L., et al. (2023). Least-to-Most Prompting Enables Complex Reasoning in Large Language Models. ICLR 2023.

A 附录 A. 提示模板

六种提示策略概述如下；逐字提示包含于复现包。

A.1 S0 基础零样本：CAICS 体系（十九类定义）+ JSON 输出格式，无推理引导。

A.2 S1 基础少样本：S0 加三个专家标注示例（文本 → 带证据编码），取自银标准。

A.3 S2 Auto-CoT：S0 加"按 M→F→T→H→C 因果链先自组织推理再编码"指令。

A.4 S3 计划与求解：S0 加"先制定分析计划再执行"指令。

A.5 S4 CAICS-CoT：共测试两版。v1 将每个编码表述为疑问式条件检查（"文本提到……吗？"）加保守指令。v2 以两步判断（显性匹配 + 授权推断，含从亡人结果推断监管缺失等先验规则）取代检查，并加全覆盖偏好。

A.6 S5 CAICS-CoT+：五次独立逐层 API 调用（层间摘要注入），加最终汇总调用。

V2 修订说明（供作者与导师查阅，投稿时删除本段）：本版依据综合评阅意见完成以下文字级修订——主线确定为"探索性数据工程系统与数据资源"，删除"首次/推翻/证明模型依赖/因果机制/专家级/替代人工/全部编码有证 *explicit/inferred/prior* 三层证据分级（对应数据库 *evidence_quality* 字段），全文统一分层统计口径； 银标准构建方式如

4.1 显式声明； *2×2* 消融降级为 ”措辞敏感性观察 *+* 实用补救 ”，删除机制性归因与 ”排除替代解释 ”表述； 人机一致性限定为 *Kappa*； 全部计数对账闭合（类型 *2,617+*未标注 *6*、等级 *2,622+*未标注 *1*、表 *2* 补非空分母列）； *M1* 数字全文统一为 *0.847/0.800*； 表引用勘误（*4.5* 节表 *7*→表 *8*）、表 *6* 脚注与数值矛盾修正； 数据治理声明扩充（逐源许可 */* 撤回机制 */* 创作 *8* 项分级。图片为占位符，待作者手绘后替换。