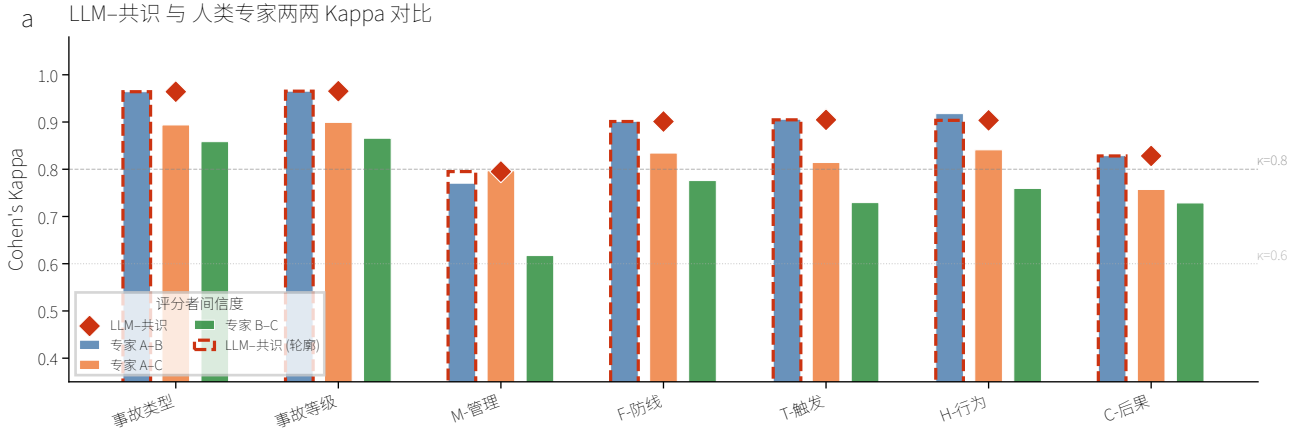
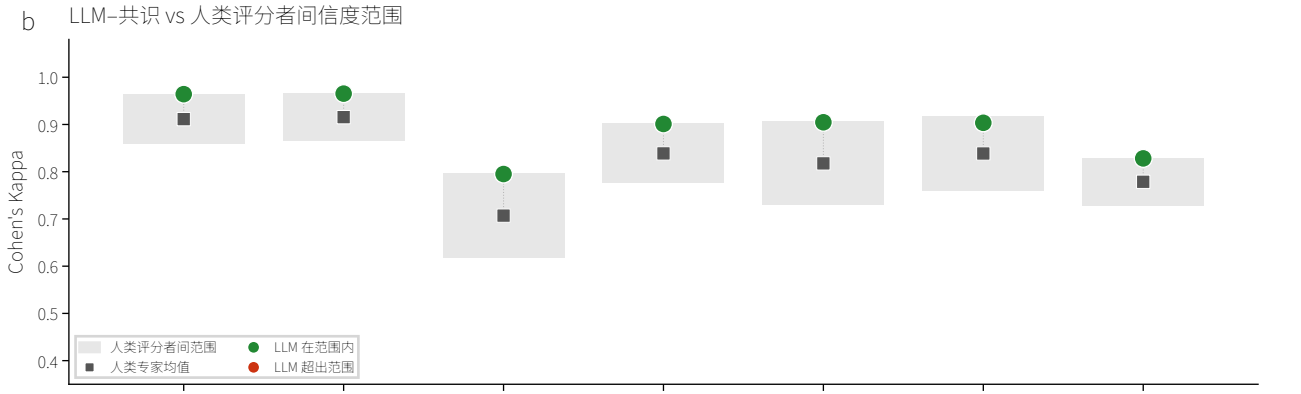
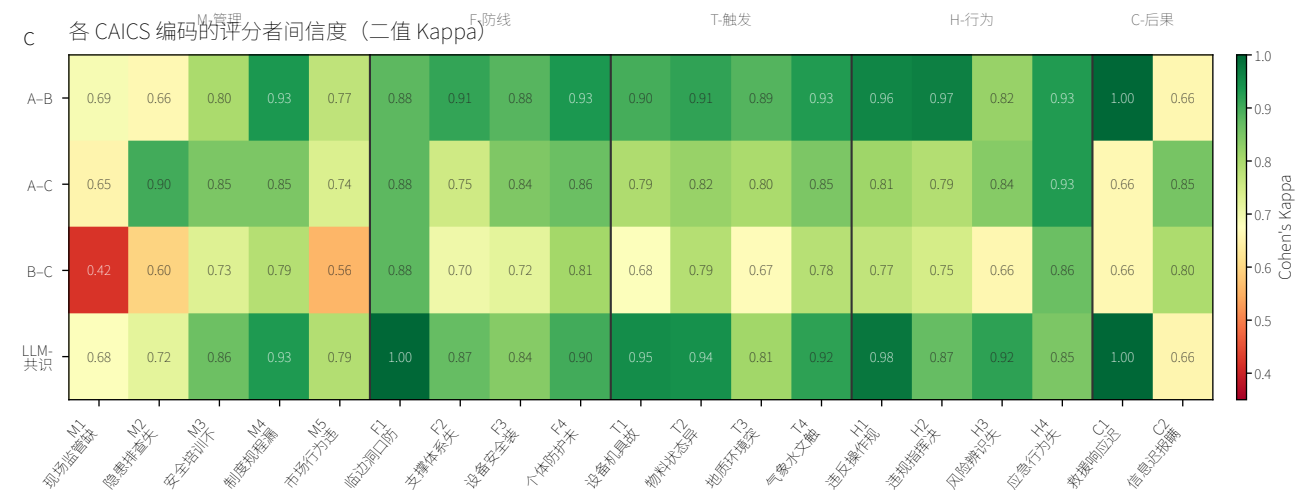

a
LLM–共识 与 人类专家两两 Kappa 对比
Cohen's Kappa
1.0
0.9
0.8
0.7
0.6
0.5
0.4
κ=0.8
κ=0.6
评分者间信度
LLM–共识
专家 A–B
专家 A–C
专家 B–C
LLM–共识 (轮廓)
事故类型
事故等级
M-管理
F-防线
T-触发
H-行为
C-后果


b
LLM–共识 vs 人类评分者间信度范围
Cohen's Kappa
1.0
0.9
0.8
0.7
0.6
0.5
0.4
人类评分者间范围
人类专家均值
LLM 在范围内
LLM 超出范围
事故类型
事故等级
M-管理
F-防线
T-触发
H-行为
C-后果


c
各 CAICS 编码的评分者间信度（二值 Kappa）
M-管理
F-防线
T-触发
H-行为
C-后果
A–B 0.69 0.66 0.80 0.93 0.77 0.88 0.91 0.88 0.93 0.90 0.91 0.89 0.93 0.96 0.97 0.82 0.93 1.00 0.66
A–C 0.65 0.90 0.85 0.85 0.74 0.88 0.75 0.84 0.86 0.79 0.82 0.80 0.85 0.81 0.79 0.84 0.93 0.66 0.85
B–C 0.42 0.60 0.73 0.79 0.56 0.88 0.70 0.72 0.81 0.68 0.79 0.67 0.78 0.77 0.75 0.66 0.86 0.66 0.80
LLM–共识 0.68 0.72 0.86 0.93 0.79 1.00 0.87 0.84 0.90 0.95 0.94 0.81 0.92 0.98 0.87 0.92 0.85 1.00 0.66
M1 现场监管缺
M2 隐患排查失
M3 安全培训不
M4 制度规程漏
M5 市场行为违
F1 临边洞口防
F2 支撑体系失
F3 设备安全装
F4 个体防护未
T1 设备机具故
T2 物料状态异
T3 地质环境突
T4 气象水文触
H1 违反操作规
H2 违规指挥决
H3 风险辨识失
H4 应急行为失
C1 救援响应迟
C2 信息迟报瞒
Cohen's Kappa
1.0
0.9
0.8
0.7
0.6
0.5
0.4